




CNN示例：LeNet-5

前向传播计算



$$z_1^{(1)} = w_{11}^{(1)} x_1 + w_{12}^{(1)} x_2 + w_{13}^{(1)} x_3 + b_1^{(1)}$$

$$z_2^{(1)} = w_{21}^{(1)} x_1 + w_{22}^{(1)} x_2 + w_{23}^{(1)} x_3 + b_2^{(1)}$$

$$z_3^{(1)} = w_{31}^{(1)} x_1 + w_{32}^{(1)} x_2 + w_{33}^{(1)} x_3 + b_3^{(1)}$$

$$a_1^{(1)} = f(z_1^{(1)})$$

$$a_2^{(1)} = f(z_2^{(1)})$$

$$a_3^{(1)} = f(z_3^{(1)})$$

反向传播算法

梯度下降法

从数学上的角度来看，梯度的方向是函数增长速度最快的方向，那么梯度的反方向就是函数减少最快的方向。那么，如果想计算一个函数的最小值，就可以使用梯度下降法的思想来做。假设希望求解目标函数 $f(\mathbf{x}) = f(x_1, \dots, x_n)$ 的最小值，可以从一个初始点 $\mathbf{x}^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)})$ 开始，基于学习率 $\eta > 0$ 构建一个迭代过程：当 $i \geq 0$ 时，


$$x_1^{(i+1)} = x_1^{(i)} - \eta \cdot \frac{\partial f}{\partial x_1}(\mathbf{x}^{(i)}),$$

...

$$x_n^{(i+1)} = x_n^{(i)} - \eta \cdot \frac{\partial f}{\partial x_n}(\mathbf{x}^{(i)}).$$

其中 $\mathbf{x}^{(i)} = (x_1^{(i)}, \dots, x_n^{(i)})$ ，一旦达到收敛条件的话，迭代就结束。

卷积运算



$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) K(m, n)$$

$$S(0, 0) = (I * K)(0, 0) = \sum_m \sum_n I(0 + m, 0 + n) K(m, n)$$

$$S(1, 0) = (I * K)(1, 0) = \sum_m \sum_n I(1 + m, 0 + n) K(m, n)$$

$$S(2, 0) = (I * K)(2, 0) = \sum_m \sum_n I(2 + m, 0 + n) K(m, n)$$

$$S(0, 1) = (I * K)(0, 1) = \sum_m \sum_n I(0 + m, 1 + n) K(m, n)$$

$$S(1, 1) = (I * K)(1, 1) = \sum_m \sum_n I(1 + m, 1 + n) K(m, n)$$

$$S(2, 1) = (I * K)(2, 1) = \sum_m \sum_n I(2 + m, 1 + n) K(m, n)$$

Convolutions



- Suppose you want to learn 9 features from a 5x5 image.

- ◆ With Fully Connected Neural Networks:

$$5 \times 5 \times 9 = 225$$

- ◆ With Locally Connected Neural Networks:

$$3 \times 3 \times 9 = 81$$

- ◆ With Weights Sharing:

$$3 \times 3 \times 1 = 9$$

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0

Image

4		


Convolved
Feature

Locally Connected Networks



FULLY CONNECTED NEURAL NET

Example: 1000x1000 image
1M hidden units
→ 10^{12} parameters!!!




- Spatial correlation is local
- Better to put resources elsewhere!

59

LOCALLY CONNECTED NEURAL NET

Example: 1000x1000 image
1M hidden units
Filter size: 10x10
100M parameters



Ranzor

Suppose there are 1M hidden units:

Left: $1000 \times 1000 \times 1M = 10^{12}$


Right: $10 \times 10 \times 1M = 10^8$

Weights Sharing



FULLY CONNECTED NEURAL NET


Example: 1000x1000 image
1M hidden units
→ 10^{12} parameters!!!



59

LOCALLY CONNECTED NEURAL NET

Example: 1000x1000 image
1M hidden units
Filter size: 10x10
100M parameters



Ranze

Suppose there are 1M hidden units:

Left: $1000 \times 1000 \times 1M = 10^{12}$

Right: $10 \times 10 \times 1 = 10^2$

卷积运算




Figure 2.1: (No padding, no strides) Convolving a 3×3 kernel over a 4×4 input using unit strides (i.e., $i = 4$, $k = 3$, $s = 1$ and $p = 0$).




Figure 2.2: (Arbitrary padding, no strides) Convolving a 4×4 kernel over a 5×5 input padded with a 2×2 border of zeros using unit strides (i.e., $i = 5$, $k = 4$, $s = 1$ and $p = 2$).

卷积运算




Figure 2.3: (Half padding, no strides) Convolving a 3×3 kernel over a 5×5 input using half padding and unit strides (i.e., $i = 5$, $k = 3$, $s = 1$ and $p = 1$).





Figure 2.4: (Full padding, no strides) Convolving a 3×3 kernel over a 5×5 input using full padding and unit strides (i.e., $i = 5$, $k = 3$, $s = 1$ and $p = 2$).

卷积运算的物理含义


$$K_{horizontal_high_magnitude} = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$



(a) Lenna



(b) Horizontal edge




(c) Vertical edge

LeNet-5



■ C1层是一个卷积层

- ◆ 6个特征图，每个特征图中的每个神经元与输入中 5×5 的邻域相连，特征图大小为 28×28 ，
- ◆ 每个卷积神经元的参数数目： $5 \times 5 = 25$ 个unit参数和一个bias参数，
- ◆ 连接数目： $(5 \times 5 + 1) \times 6 \times (28 \times 28) = 122,304$ 个连接
- ◆ 参数共享：每个特征图内共享参数，因此参数总数：共 $(5 \times 5 + 1) \times 6 = 156$ 个参数




LeNet-5



■ S2层是一个下采样层

- ◆ 6个 14×14 的特征图，每个图中的每个单元与C1特征图中的一个 2×2 邻域相连接，不重叠。因此，S2中每个特征图的大小是C1中特征图大小的 $1/4$ 。
- ◆ S2层每个单元的4个输入相加，乘以一个可训练参数 w ，再加上一个可训练偏置 b ，结果通过sigmoid函数计算。
- ◆ 连接数： $(2 \times 2 + 1) \times 1 \times 14 \times 14 \times 6 = 5880$ 个
- ◆ 参数共享：每个特征图内共享参数，因此有 $(2 \times 2 + 1) \times 6 = 30$ 个可训练参数




LeNet-5



■ C3层是一个卷积层

- ◆ 16个卷积核，得到16张特征图，特征图大小为 10×10 ；
- ◆ 每个特征图中的每个神经元与S2中某几层的多个 5×5 的邻域相连；

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
0	X					X	X	X		X	X	X	X		X	X
1	X	X				X	X	X		X	X	X	X		X	X
2	X	X	X			X	X	X		X		X	X	X	X	X
3		X	X	X			X	X	X	X		X		X	X	X
4			X	X	X			X	X	X	X		X	X	X	X
5				X	X	X			X	X	X	X		X	X	X



LeNet-5




■ C3层是一个卷积层

- ◆ 16个卷积核，得到16张特征图，特征图大小为 10×10 ；
- ◆ 每个特征图中的每个神经元与S2中某几层的多个 5×5 的邻域相连；

- 例如，对于C3层第0张特征图，其每一个节点与S2层的第0张特征图，第1张特征图，第2张特征图，总共3个 5×5 个节点相连接。

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
0	X					X	X	X		X	X	X	X		X	X
1	X	X				X	X	X		X	X	X	X		X	X
2	X	X	X			X	X	X		X		X	X	X	X	X
3		X	X	X			X	X	X	X		X		X	X	X
4			X	X	X			X	X	X	X		X	X	X	X
5				X	X	X			X	X	X	X		X	X	X




LeNet-5



■ S4层是一个下采样层

- ◆ 由16个5*5大小的特征图构成，特征图中的每个单元与C3中相应特征图的2*2邻域相连接；
- ◆ 连接数： $(2*2+1)*5*5*16=2000$ 个
- ◆ 参数共享：特征图内共享参数，每张特征图中的每个神经元需要1个因子和一个偏置，因此有 $2*16$ 个可训练参数




LeNet-5



■ C5层

- ◆ 120个神经元，可以看作120个特征图，每张特征图的大小为1*1
- ◆ 每个单元与S4层的全部16个单元的5*5邻域相连（S4和C5之间的全连接）
- ◆ 连接数=可训练参数： $(5*5*16+1)*120=48120$ 个




LeNet-5



■ F6层

- ◆ 有84个单元（之所以选这个数字的原因来自于输出层的设计），与C5层全相连。
- ◆ F6层计算输入向量和权重向量之间的点积，再加上一个偏置。
- ◆ 连接数=可训练参数： $(120+1) * 84 = 10164$
- ◆ 84 : stylized image : $7 * 12$




LeNet-5



■ 输出层采用欧式径向基函数 (Euclidean Radial Basis Function) 单元

- ◆ 给定一个输入模式，损失函数应能使得F6的配置与RBF参数向量（即模式的期望分类）足够接近。
- ◆ 每类一个单元，每个单元连接84个输入；每个输出RBF单元计算输入向量和参数向量之间的欧式距离。
- ◆ RBF输出可以被理解为F6层配置空间的高斯分布的【-log-likelihood】



60,000 original datasets

Test error: 0.95%

[illegible]

•

Test error: 0.8%

错误识别分析



4	3	2	1	5	4	2	3	6	1
4->6	3->5	8->2	2->1	5->3	4->8	2->8	3->5	6->5	7->3
4	8	7	5	8	6	3	2	8	4
9->4	8->0	7->8	5->3	8->7	0->6	3->7	2->7	8->3	9->4
8	5	4	3	6	2	4	6	9	1
8->2	5->3	4->8	3->9	6->0	9->8	4->9	6->1	9->4	9->1
4	0	6	3	2	9	6	6	6	8
9->4	2->0	6->1	3->5	3->2	9->5	6->0	6->0	6->0	6->8
4	7	4	4	2	9	4	9	9	4
4->6	7->3	9->4	4->6	2->7	9->7	4->3	9->4	9->4	9->4
2	4	8	3	8	6	8	3	3	9
8->7	4->2	8->4	3->5	8->4	6->5	8->5	3->8	3->8	9->8
1	9	6	0	6	9	0	6	4	2
1->5	9->8	6->3	0->2	6->5	9->5	0->7	1->6	4->9	2->1
2	8	4	7	7	6	9	6	6	5
2->8	8->5	4->9	7->2	7->2	6->5	9->7	6->1	5->6	5->0
4	2								
4->9	2->8								